Do Simbólico à Incerteza: previsão de hospitalização em casos notificados de dengue

Antony Wesley Pimentel Oliveira
João Pedro do Nascimento Seixas
José Henrique da Cruz Costa
Kauã de Souza Viana
Livia Karolina Gomes do Nascimento
Nelson Junior Rocha dos Santos

Novembro de 2026

Resumo

Este trabalho aplica, a um mesmo problema de saúde pública, o pipeline completo de aprendizado visto na disciplina de Fundamentos de IA: árvore de decisão, regressão linear e logística, probabilidade, Naive Bayes com EM, redes Bayesianas e lógica fuzzy. A partir das notificações de dengue de 2026 do Sinan, buscamos responder se um paciente notificado será hospitalizado, a partir do seu perfil e dos sintomas registrados. A árvore, a regressão logística, o Naive Bayes e a rede Bayesiana ficaram entre 65,7% e 66,9% de acurácia em uma base balanceada, e a leucopenia, a idade avançada, a hipertensão e as regiões Nordeste e Norte apareceram de forma consistente como os principais fatores associados à hospitalização. Por fim, um sistema fuzzy combina a probabilidade da rede Bayesiana com sinais de alarme em uma decisão interpretável, que aumenta a identificação de casos hospitalizados ao custo de mais falsos positivos.

1 Introdução

A dengue é uma das principais arboviroses do Brasil, e todo caso suspeito deve ser notificado ao Sistema de Informação de Agravos de Notificação (Sinan). A maior parte dos casos evolui de forma leve, mas uma parcela precisa ser hospitalizada, e antecipar quais pacientes têm maior chance de internação pode ajudar na triagem e no planejamento dos serviços de saúde. A equipe escolheu o domínio de Saúde Pública e a pergunta:

> *Dado o perfil e os sintomas de um paciente com dengue notificado, ele será hospitalizado?*

Para respondê-la, percorremos as seis etapas do pipeline [1]: árvore de decisão, regressão linear e logística, probabilidade, Naive Bayes com EM, redes Bayesianas e lógica fuzzy. A Seção 2 descreve os dados; as Seções 3 a 8, cada etapa; a Seção 9, a integração; a Seção 10, a equipe; e a Seção 11 conclui.

2 Dados

Usamos os microdados de notificações de dengue de 2026 do Sinan (`DENGBR26.csv`, Portal de Dados Abertos do SUS [5]), com 470.451 registros.

Variável-alvo. `HOSPITALIZ` indica se o paciente foi hospitalizado (1 = sim, 2 = não, 9 = ignorado). Mantivemos os 346.765 registros com desfecho conhecido, descartando 123.686 (ignorados, em branco ou inválidos). Apenas 8,56% deles são hospitalizações.

Atributos derivados. A *faixa etária* vem de `NU_IDADE_N` (criança: menos de 12 anos; adulto: 12 a 59; idoso: 60 ou mais) e a *região*, do primeiro dígito do código IBGE do estado de notificação. Os registros usados se concentram no Sudeste (126.527) e no Centro-Oeste (109.840), seguidos de Nordeste (76.589), Norte (22.337) e Sul (11.472); 75,6% são adultos.

Vazamento do alvo. Excluímos colunas preenchidas depois ou por causa da internação, que entregariam a resposta: `DT_INTERNA`, `CLASSI_FIN`, `CRITERIO`, `EVOLUCAO`, os sinais de alarme (`ALRM_*`) e de gravidade (`GRAV_*`).

Balanceamento e divisão. Prever sempre "não hospitalizado" já daria 91,4% de acerto. Por isso aplicamos *undersampling*, obtendo 59.380 registros com proporção 50/50, divididos de forma estratificada em treino (47.504) e teste (11.876). Usamos semente fixa (`seed = 42`) em todo o trabalho.

3 Etapa 1 Árvore de decisão

Implementamos o ID3 do zero, com entropia e ganho de informação, e o comparamos com o `DecisionTreeClassifier` do scikit-learn [6].

Seleção de atributos. Dos 17 candidatos (perfil, localização, sintomas e comorbidades), os maiores ganhos no treino foram estado (0,066), região (0,045), leucopenia (0,029), faixa etária (0,017), vômito (0,015), cefaleia (0,014) e hipertensão (0,009); sexo e artralgia ficaram praticamente em zero. Uma

Tabela 1: Divisão da raiz pela região (treino).

Região	Não	Sim	Entropia	Peso
Centro-Oeste	7.623	5.390	0,97865	0,27393
Nordeste	4.848	9.544	0,92178	0,30296
Norte	1.471	2.383	0,95922	0,08113
Sudeste	9.025	5.645	0,96136	0,30882
Sul	785	790	0,99999	0,03316

primeira versão, só com perfil e sintomas, teve 60,6% de acurácia no teste; incluir o estado a elevou a 68,7%. A versão final troca o estado pela região e usa seis atributos interpretáveis: região, leucopenia, faixa etária, vômito, cefaleia e hipertensão (66,3% no teste). A troca custa cerca de 2,4 pontos percentuais, mas o estado tem 27 valores e boa parte do seu ganho reflete critérios locais de notificação, e não risco clínico; a diferença está, ainda, dentro da variação entre amostras.

Entropia e ganho. Com o treino balanceado (23.752 casos por classe), $H(\text{raiz}) = 1$. A raiz escolhida foi a região (Tabela 1). Para o Centro-Oeste, com $p = 5.390/13.013 = 0{,}4142$, $H = -(0{,}4142 \log_2 0{,}4142 + 0{,}5858 \log_2 0{,}5858) \approx 0{,}97865$. A entropia ponderada dos filhos é

$$H(\text{filhos}) = \textstyle\sum_v \frac{|S_v|}{|S|} H(S_v) = 0{,}95521,$$
$$\text{Ganho(região)} = 1 - 0{,}95521 = 0{,}04479.$$

A Tabela 2 mostra os níveis 2 e 3, obtidos repetindo a conta dentro de cada nó. Em todas as regiões em que aparece, a leucopenia eleva bastante a proporção de hospitalizados (no Centro-Oeste, 75,7% contra 38,0%), assim como o vômito no Nordeste. Essas proporções valem para a base balanceada, e parte das diferenças regionais pode refletir o preenchimento das notificações, e não só o risco clínico.

Comparação e validação cruzada. O ID3 do zero e o scikit-learn (entropia, sem poda) tiveram exatamente a mesma acurácia: 66,70% no treino e 66,32% no teste. A árvore sem poda e a de profundidade 5 são praticamente equivalentes: 66,32% e 66,39% no teste, 66,27% e 66,19% em validação 5-fold (Tabela 3). Adotamos a profundidade 5 por ser mais compacta, sem perda notável de desempenho. No scikit-learn, `max_depth` conta divisões binárias sobre variáveis indicadoras, por isso não equivale à profundidade do ID3. A acurácia ficou abaixo da referência do enunciado (72–80%); como treino e teste são próximos, o modelo não está sobreajustado, e a limitação está na informação disponível (Seção 11).

Monotonicidade. Na lógica clássica, a dedução é monotônica: uma conclusão continua valendo quando novas premissas são acrescentadas. A indução não tem essa propriedade, e isso ocorreu neste trabalho. Em uma execução anterior, com 13.689 exemplos de treino, o ID3 escolheu a leucopenia como raiz (ganho 0,03517) por margem mínima sobre a região (0,03486). Com os 47.504 exemplos, a conclusão se inverteu (região 0,04479; leucopenia 0,02936), e a árvore inteira mudou de forma. Com uma diferença de 0,0003 entre os dois melhores atributos, poucos exemplos bastam para inverter a escolha. Além disso, a amostra parcial não era representativa: o Sul tinha apenas 5 casos, quando uma amostra aleatória desse tamanho teria cerca de 450. Mesmo assim, o ponto central se mantém: a raiz depende dos exemplos vistos. Como o Sinan é atualizado continuamente, a árvore é provisória, e a validação cruzada (66,3% em média, entre 65,6% e 66,8%) estima o desempenho, mas não garante que as conclusões se mantenham.

O que aprendemos. A indução não é monotônica: novos dados podem mudar a raiz e toda a árvore. Sem as colunas que vazam o alvo, a acurácia parou em cerca de 66%, o que sugere que o limite está nos dados, e não no algoritmo. Mesmo assim, a árvore produziu regras fáceis de interpretar.

4 Etapa 2 Aprendizado linear

A regressão linear exige um alvo contínuo, então mudamos a unidade de análise para o município: o alvo passou a ser a *taxa de hospitalização* municipal, e os atributos, as proporções de idosos, crianças e casos com vômito, leucopenia, cefaleia e hipertensão, além do log do número de casos. Mantivemos os 436 municípios com pelo menos 100 casos (348 no treino e 88 no teste). A taxa média foi de 9,9%, variando de 0% a 92,7%.

Univariada e multivariada. Com a proporção de crianças, o atributo mais correlacionado ($r = 0{,}385$), a fórmula fechada deu $b_1 = S_{xy}/S_{xx} = 1{,}66389/3{,}27057 = 0{,}50875$ e $b_0 = \bar{y} - b_1\bar{x} = 0{,}01869$. Na multivariada, o gradiente descendente vetorizado, com atributos padronizados, reduziu o erro quadrático médio de 0,0236 para 0,0102 e chegou aos mesmos coeficientes das equações normais (diferença de 10^{-14}).

Ridge (L2). Sem penalizar o intercepto e com λ escolhido por validação 5-fold no treino, o ótimo foi $\lambda = 0{,}273$, que elevou o R^2 da validação de 0,181 para 0,193. A Figura 1 mostra os coeficientes encolhendo conforme λ cresce, e a Tabela 4 traz os valores de R^2. As implementações do zero deram os mesmos coeficientes que o scikit-learn.

Os R^2 ficaram abaixo da referência (0,55 a 0,82). A taxa municipal provavelmente depende de fatores fora dos dados, como a estrutura de saúde e a forma de notificar: municípios com taxas acima de 80% sugerem que lá só os casos graves são notificados. No teste, o Ridge ficou um pouco abaixo da regressão comum, mas, com 88 municípios, essa diferença está dentro da variação entre amostras.

Tabela 2: Níveis 2 e 3 da árvore (treino). Nos sintomas, 1 = sim e 2 = não.

Nível	Nó	n	Não	Sim	Entropia	Divide por	Ganho
2	Centro-Oeste	13.013	7.623	5.390	0,9787	leucopenia	0,03509
3	leucopenia = sim	1.185	288	897	0,8001	vômito	0,01556
3	leucopenia = não	11.828	7.335	4.493	0,9579	faixa etária	0,02288
2	Nordeste	14.392	4.848	9.544	0,9218	vômito	0,02319
3	vômito = sim	5.391	1.235	4.156	0,7764	leucopenia	0,01436
3	vômito = não	9.001	3.613	5.388	0,9718	leucopenia	0,02381
2	Norte	3.854	1.471	2.383	0,9592	leucopenia	0,01977
3	leucopenia = sim	424	70	354	0,6464	faixa etária	0,01363
3	leucopenia = não	3.430	1.401	2.029	0,9757	vômito	0,01809
2	Sudeste	14.670	9.025	5.645	0,9614	faixa etária	0,03359
3	adulto	10.483	7.107	3.376	0,9066	leucopenia	0,02346
3	criança	2.081	1.099	982	0,9977	cefaleia	0,02473
3	idoso	2.106	819	1.287	0,9641	leucopenia	0,02975
2	Sul	1.575	785	790	1,0000	leucopenia	0,03119
3	leucopenia = sim	180	39	141	0,7540	vômito	0,04313
3	leucopenia = não	1.395	746	649	0,9965	faixa etária	0,02387

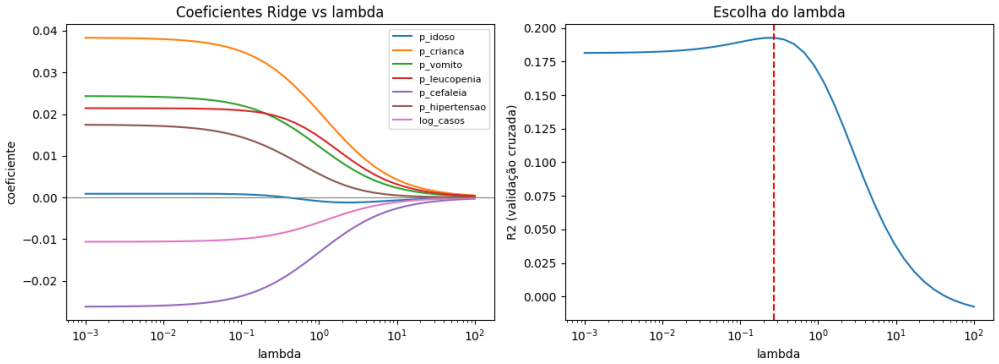


Figura 1: Coeficientes do Ridge em função de λ (esquerda) e R^2 da validação cruzada (direita); a linha tracejada marca o λ ótimo.

Tabela 3: Resultados da Etapa 1.

Modelo	Treino	Teste	5-fold
ID3 sem poda	0,6670	0,6632	0,6627
ID3, prof. 5	0,6653	0,6639	0,6619
sklearn sem poda	0,6670	0,6632	0,6627
sklearn, prof. 5	0,6571	0,6519	0,6560

Tabela 4: Regressões por município (R^2).

Modelo	Treino	Teste
Univariada (crianças)	0,1687	0,0752
Multivariada (GD)	0,2949	0,3114
Ridge ($\lambda = 0{,}273$)	0,2840	0,2839

Regressão logística. Implementada do zero (sigmoide e gradiente da entropia cruzada) com o treino, o teste e os atributos da Etapa 1, ela coincidiu com o scikit-learn: 66,57% no treino e 66,43% no teste, com precisão de 65,86% e recall de 68,22%. Os coeficientes viram razões de chance: ter leucopenia multiplica a chance de hospitalização por cerca de 4,3; vômito, por 1,8; hipertensão, por 1,75; ser idoso, por 2,1 em relação aos adultos; e Nordeste e Norte têm chances 3,0 e 2,4 vezes maiores que o Centro-Oeste. A cefaleia aparece associada a chance menor, talvez por ser mais registrada em casos leves.

O que aprendemos. Quando a técnica exige um alvo contínuo, é possível mudar a unidade de análise. O R^2 baixo indica que a taxa municipal depende de fatores fora dos dados, e a regressão logística mostrou o valor de interpretar coeficientes como razões de chance.

5 Etapa 3 Probabilidade

Usamos os 346.765 registros com desfecho conhecido, *sem* balanceamento, para que as probabilidades reflitam as frequências reais, com as variáveis hospitalização (H), leucopenia (L) e vômito (V). Todos os registros têm valores válidos nas três.

Conjunta, marginais e condicionais. A Tabela 5 traz os quatro eventos atômicos, que somam 1. As marginais são $P(H) = 0{,}0856$ e $P(L) = 0{,}0467$, e

$$P(H \mid L) = \frac{P(H,L)}{P(L)} \approx 0{,}2808, \quad P(H \mid \neg L) \approx 0{,}0760,$$

uma associação forte, mas que não comprova causa.

Regra da cadeia. $P(H, L, V) = P(H)\,P(L \mid H)\,P(V \mid H, L) \approx 0{,}0856 \cdot 0{,}1533 \cdot 0{,}4732 \approx 0{,}0062$, igual à frequência conjunta observada.

Tabela 5: Distribuição conjunta de H e L.

	L = sim	L = não
H = sim	0,0131	0,0725
H = não	0,0336	0,8808

Teorema de Bayes. $P(H \mid L) = P(L \mid H)\,P(H)/P(L) \approx 0{,}1533 \cdot 0{,}0856/0{,}0467 \approx 0{,}2808$. $P(L \mid H)$ corresponde à direção causal, a frequência da leucopenia entre os hospitalizados; a rigor, a internação não causa a leucopenia, e ambas decorrem da gravidade do caso, da qual a hospitalização é um indicador. $P(H \mid L)$ é a direção diagnóstica, que parte do que se observa para estimar o desfecho, como na triagem. Bayes permite passar de uma à outra, mas nenhuma das duas demonstra causalidade.

Independência condicional. $P(L, V \mid H) = 0{,}0725$, enquanto $P(L \mid H)\,P(V \mid H) \approx 0{,}1533 \cdot 0{,}4202 = 0{,}0644$. Leucopenia e vômito não são exatamente independentes entre os hospitalizados, o que é relevante para a Etapa 4, já que o Naive Bayes supõe essa independência.

Limitações da lógica. A lógica de primeira ordem pode afirmar que um sintoma implica internação, mas não que um paciente tem 70% de chance de ser internado: ou a regra vale para todos os casos, ou não vale. A probabilidade representa essa incerteza, essencial quando pacientes com os mesmos sintomas têm desfechos diferentes.

O que aprendemos. Probabilidades devem ser calculadas na base sem balanceamento. O Teorema de Bayes permite passar da direção causal para a diagnóstica, e a probabilidade expressa a incerteza que a lógica de primeira ordem não representa.

6 Etapa 4 Naive Bayes e EM

Usamos o mesmo treino, teste e atributos da Etapa 1.

MLE e MAP. Para uma Bernoulli com k sucessos em n, $\hat{\theta}_{MLE} = k/n$ e o MAP com prior Beta(a, b) é $(k+a-1)/(n+a+b-2)$; com Beta(2,2), $(k+1)/(n+2)$, a suavização de Laplace. Na base inteira, os dois coincidem (0,085620 e 0,085622). Em amostras pequenas, não: com $n = 5$, em 62,8% das amostras bootstrap ninguém foi hospitalizado, e o MLE conclui $\theta = 0$. A prior Beta(2,2), centrada em 0,5, teve erro médio um pouco maior que o MLE (0,1221 contra 0,1127 com $n = 5$), enquanto uma prior informada, Beta(2,12), reduziu o erro para 0,0336: o MAP só ajuda quando a prior traduz conhecimento razoável. No Naive Bayes, com apenas 20 exemplos de treino, o MLE gerou probabilidade zero para 35,6% dos pacientes do teste (log-loss de 4,34, contra 0,75 com MAP). Por isso as Etapas 4 e 5 usam o MAP.

Tabela 6: Naive Bayes, NB + EM e a árvore da Etapa 1.

Modelo	Treino	Teste	5-fold	AUC	log-loss
NB puro	0,6623	0,6689	0,6636	0,7251	0,6105
NB + EM (K=2)	0,6620	0,6688	0,6638	0,7259	—
NB + EM (K=3)	0,6660	0,6644	0,6657	0,7269	0,6092
ID3 (Etapa 1)	0,6670	0,6632	0,6627	—	—

Naive Bayes do zero. $P(C, x) = P(C)\prod_j P(x_j \mid C)$, com tabelas estimadas por contagem. A leucopenia é 4,1 vezes mais frequente entre os hospitalizados, e a hipertensão e a faixa idosa, cerca de 1,9 vez. A implementação produziu as mesmas probabilidades que o `CategoricalNB` (diferença de 10^{-15}), com 66,89% de acurácia e AUC de 0,725 no teste.

EM com variável oculta. Para relaxar a independência condicional, que a Etapa 3 mostrou não valer exatamente, introduzimos uma variável oculta Z com K componentes em cada classe:

$$P(C, x) = P(C)\sum_k P(Z{=}k \mid C)\prod_j P(x_j \mid Z{=}k, C).$$

Como os atributos são categóricos, usamos uma mistura de distribuições categóricas em vez da gaussiana do pseudocódigo: o passo E calcula $P(Z = k \mid x)$ para cada paciente, e o passo M reestima as tabelas com as contagens esperadas. A inicialização é aleatória, então o EM é rodado várias vezes. A log-verossimilhança cresceu em todas as iterações e terminou acima da do Naive Bayes (Figura 2), mas levou mais iterações que a faixa do enunciado (15 a 30): 99% do ganho veio entre 30 e 61 iterações com $K = 3$, e entre 75 e 116 com $K = 2$.

O K foi escolhido por validação cruzada no treino ($K = 3$). O EM melhorou um pouco a validação e a AUC (Tabela 6) e também o log-loss no teste (de 0,6105 para 0,6092), mas as acurácias ficaram abaixo da referência (72–78% e 80–86%): a variável oculta só reorganiza os mesmos seis atributos. O mais interessante foi o que Z aprendeu: entre os hospitalizados, um perfil (23%) reúne idosos, metade deles hipertensos; outro (41%), crianças, sobretudo do Nordeste; e o terceiro (35%), adultos. O EM encontrou sozinho a dependência entre idade e hipertensão, depois usada na Etapa 5.

O que aprendemos. Em amostras pequenas, o MLE gera probabilidades zero que anulam o Naive Bayes, e o MAP evita isso. O EM relaxou a independência condicional, e Z funcionou como um agrupador automático de perfis de pacientes.

7 Etapa 5 Redes Bayesianas

Estrutura e CPTs. A rede tem seis nós: a hospitalização (`HOSP`) e cinco atributos da Etapa 1 (Figura 3); a cefaleia ficou de fora, por ter a associação mais fraca. As arestas seguem o sentido causal. A idade influencia a hipertensão (0,6% das crianças, 6,9% dos adultos e 43,6% dos idosos são hipertensos),

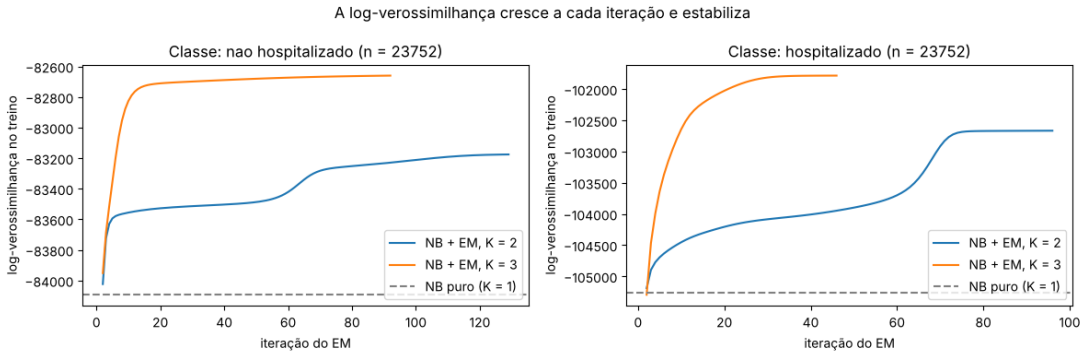


Figura 2: Log-verossimilhança do EM no treino, por classe. A linha tracejada é o Naive Bayes puro.

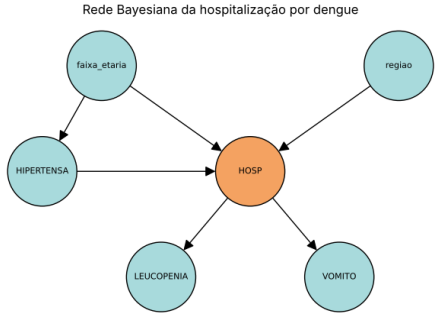


Figura 3: DAG da rede Bayesiana.

e idade, hipertensão e região influenciam a internação. Leucopenia e vômito são tratados como manifestações do caso grave, que `HOSP` representa: o vômito persistente é sinal de alarme, e o internado faz mais exames, o que aumenta o registro de leucopenia. Isso indica uma limitação: se parte da leucopenia registrada existe porque o paciente foi internado, esse atributo carrega algum vazamento do alvo, e sua forte associação com a hospitalização, vista em todas as etapas, deve ser lida com cautela. As CPTs foram estimadas no treino com MAP. Como o treino é balanceado, corrigimos cada probabilidade p para a prevalência real $\pi \approx 8{,}6\%$ por $p_{real} = p\pi/[p\pi + (1-p)(1-\pi)]$.

Inferência por enumeração. Implementada do zero, ela soma a conjunta sobre as variáveis não observadas e normaliza. Para um idoso com leucopenia, somando sobre região, hipertensão e vômito, $P(\text{HOSP} = \text{sim} \mid e) = 0{,}892$ na base balanceada, ou 0,436 na prevalência real (Tabela 7). Os resultados foram idênticos aos da eliminação de variáveis do `pgmpy` [7] (diferença máxima de $2{,}2 \times 10^{-16}$ em 300 consultas). Na direção diagnóstica, $P(\text{leucopenia} \mid \text{HOSP}) = 0{,}151$, contra 0,037 entre os não hospitalizados.

d-separação e colisor. Implementamos a d-separação pelo grafo ancestral moralizado, conferida com o `pgmpy`. Leucopenia e vômito são independentes dado `HOSP` (causa comum), assim como hipertensão e leucopenia (cadeia): $P(\text{leucopenia} \mid \text{HOSP} = \text{sim}, \text{vômito})$ vale 0,1513 com ou sem vômito, mas, sem observar `HOSP`, vai de 0,088 a 0,105. Essa independência é imposta pelo DAG; nos dados, a Etapa 3 mostrou que ela vale só aproximadamente. `HOSP` é um colisor em região $\rightarrow$ `HOSP` $\leftarrow$ idade. Sem evidência, $P(\text{NE}) = P(\text{NE} \mid \text{idoso}) = 0{,}303$; observando o colisor, $P(\text{NE} \mid \text{HOSP} = \text{sim}) = 0{,}403$, mas $P(\text{NE} \mid \text{HOSP} = \text{sim}, \text{idoso}) = 0{,}344$: saber que o internado é idoso "explica" parte da internação. O efeito aparece nos dados: o *undersampling* selecionou pacientes pelo valor de `HOSP`, o que equivale a observar o colisor, e a informação mútua entre região e idade passou de 0,0061 bit na base natural para 0,0103 bit no treino.

Tabela 7: Consultas: $P(\text{HOSP} = \text{sim} \mid e)$.

Evidência	Balanceada	Real
nenhuma	0,498	0,085
idoso	0,669	0,159
idoso, hipertenso	0,747	0,217
idoso, com leucopenia	0,892	0,436
adulto do SE, sem leuc. e vômito	0,252	0,031
criança do NE, com leuc. e vômito	0,943	0,607

Parâmetros e desempenho. A conjunta das seis variáveis exigiria 239 parâmetros; a rede usa 43 (82% a menos) e descreveu melhor os pacientes do teste que a estrutura Naive Bayes (19 parâmetros) e que `HOSP` com todos os atributos como pais (129), com log-verossimilhança média de $-4{,}057$, contra $-4{,}122$ e $-4{,}127$. Como classificador, teve 65,67% de acurácia no teste (65,71% em 5-fold) e AUC de 0,715. As probabilidades são bem ordenadas: acima de 0,7, 81% dos pacientes foram hospitalizados; abaixo de 0,3, 27%. Elas são a entrada da Etapa 6.

O que aprendemos. Um DAG traduz o conhecimento do domínio em estrutura e reduz muito os parâmetros, e o colisor mostrou que observar uma variável, ou selecionar a amostra por ela, cria dependências entre causas independentes.

8 Etapa 6 Lógica fuzzy

Implementamos do zero um sistema de inferência fuzzy [2] do tipo Mamdani [3], conferido com o `scikit-fuzzy` [8] (diferença máxima de 10^{-4} em uma

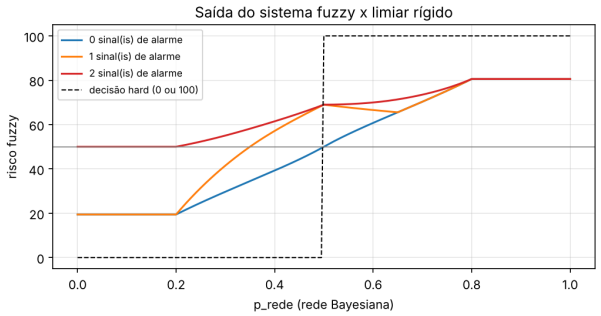


Figura 4: Risco fuzzy em função da probabilidade da rede, para 0, 1 e 2 sinais, e a decisão rígida.

Tabela 8: Decisão fuzzy x rígida (11.876 pacientes de teste).

Decisão	Acur.	Precisão	Recall	AUC
Rígida ($p \geq 0{,}5$)	0,6567	0,6628	0,6379	0,7147
Fuzzy (risco ≥ 50)	0,6275	0,6033	0,7447	0,7060

escala de 0 a 100). As entradas são a probabilidade de hospitalização da rede da Etapa 5 (baixa, média, alta) e o número de sinais de alarme presentes, leucopenia e vômito, de 0 a 2 (nenhum, um, dois)[1]. A saída é o risco de hospitalização, de 0 a 100 (baixo, moderado, alto). As funções de pertinência são triangulares, com trapézios só nos extremos dos universos; o E usa o mínimo, o OU e a agregação usam o máximo, e a defuzzificação usa o centróide. A decisão é "hospitalizar" quando o risco é pelo menos 50. As regras são:

1. Se a probabilidade é alta OU há dois sinais, o risco é alto.
2. Se a probabilidade é média, o risco é moderado.
3. Se a probabilidade é baixa, o risco é baixo.
4. Se a probabilidade é média E há um sinal, o risco é alto.

O risco acompanha a rede, e os sinais o reforçam quando a rede está em dúvida, como em um protocolo que manda reavaliar pacientes com sinal de alarme. Sem sinais, o risco cresce de forma contínua e cruza 50 exatamente em 0,5, como o limiar rígido (Figura 4). Com um sinal, há uma pequena queda entre 0,5 e 0,65, porque a regra 2 continua ativa nessa faixa; como o risco fica sempre acima de 50, ela não altera nenhuma decisão, mas indica que a base de regras poderia ser refinada.

As regras com sinais de alarme mudaram a decisão de 13,6% dos pacientes, todos de "não" para "sim" (Tabela 8). O recall subiu de 63,8% para 74,5%, mas só 39% desses pacientes foram hospitalizados, e a acurácia caiu. O motivo aparece na fronteira: entre 0,40 e 0,60, os pacientes com um sinal foram hospitalizados com frequência um pouco *menor* (46%) que os

[1]Usamos "sinais de alarme" por simplicidade: no protocolo do Ministério da Saúde, a leucopenia não é sinal de alarme, e o vômito só o é quando persistente. Os campos `ALRM_*` foram excluídos por vazamento do alvo.

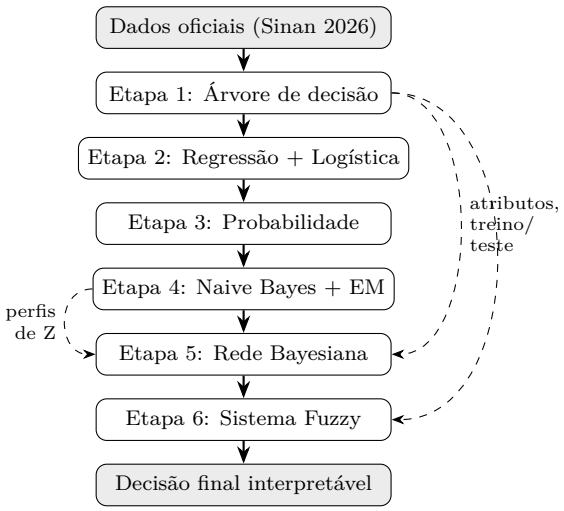


Figura 5: Integração. As setas tracejadas indicam o reuso dos atributos e do treino/teste da Etapa 1 nas Etapas 5 e 6, e dos resultados da Etapa 4 na Etapa 5.

sem sinal (48,5%). Como leucopenia e vômito já são nós da rede, contá-los de novo não acrescenta informação. O ganho do fuzzy está em outro lugar [4]: cada regra é legível e ajustável por um especialista, a decisão de cada paciente é explicada pelas regras que dispararam, a saída mostra o quanto o paciente está perto da fronteira, e a troca entre recall e precisão fica explícita; em triagem, deixar de identificar um caso grave costuma ser pior que reavaliar um leve. O fuzzy tende a superar o limiar rígido quando a segunda entrada traz algo que o modelo não viu, como a avaliação do médico, e quando as fronteiras entre as classes são ambíguas.

O que aprendemos. O fuzzy traduz probabilidades em termos próximos do raciocínio de triagem e explicita a troca entre recall e precisão, mas só melhora a decisão quando as regras trazem informação que o modelo anterior não usou.

9 Integração do pipeline

A Etapa 1 definiu a pergunta, os atributos e a divisão treino/teste, reutilizados nas Etapas 2, 4, 5 e 6 (Figura 5). A Etapa 3 mostrou que os atributos não são independentes dada a classe, o que motivou a variável oculta da Etapa 4. O EM revelou a dependência entre idade e hipertensão, incorporada à rede da Etapa 5, cujas probabilidades alimentam o sistema fuzzy da Etapa 6.

10 Organização da equipe

João Pedro baixou os dados, propôs a pergunta, desenvolveu as Etapas 1 e 2, salvou a divisão treino/teste reutilizada nas demais etapas e criou o repositório. Kauã desenvolveu a Etapa 3, Henrique as Etapas 4 e 5, e Nelson a Etapa 6. Lívia e Antony redigiram e revisaram o relatório; ao conferir os notebooks com o enunciado, Lívia identificou um erro de importação

nas Etapas 4 e 5 e, na primeira versão da Etapa 6, o uso de dados simulados e um erro nas métricas, corrigidos com apoio de um assistente de IA (Apêndice A). Cada membro documentou no README a execução da sua etapa.

11 Conclusão

A árvore, a regressão logística, o Naive Bayes e a rede Bayesiana ficaram entre 65,7% e 66,9% de acurácia no teste balanceado, abaixo das referências do enunciado. A explicação provável é a mesma em todas as etapas: sem as colunas que entregariam a resposta, sobram sintomas gerais e dados de perfil, que carregam pouca informação sobre o desfecho, e modelos mais flexíveis, como o NB com EM, não superam esse limite.

As conclusões, porém, foram consistentes entre as etapas. A leucopenia foi o sintoma mais associado à internação na árvore, na regressão logística, nas probabilidades condicionais e nas CPTs, embora parte disso possa vir de exames feitos após a internação; idade avançada, hipertensão e as regiões Nordeste e Norte também se associaram a maior risco. As etapas probabilísticas acrescentaram o que a lógica não expressa: graus de incerteza, a correção para a prevalência real e efeitos como o do colisor, que mostrou que o próprio balanceamento pode criar dependências artificiais. O sistema fuzzy transformou a probabilidade da rede em uma decisão interpretável, com regras legíveis, e deixou explícita a troca entre identificar mais casos graves e gerar mais falsos alarmes. Como extensão, a segunda entrada do fuzzy poderia vir de outra etapa, como o NB com EM ou a folha da árvore, trazendo informação nova. O principal aprendizado é que, quando os dados limitam o desempenho, o valor dos métodos está em tornar a decisão transparente, coerente entre as etapas e fácil de discutir com quem vai usá-la.

Referências

[1] S. Russell e P. Norvig. *Artificial Intelligence: A Modern Approach*. 4. ed. Pearson, 2020.

[2] L. A. Zadeh. Fuzzy sets. *Information and Control*, 8(3):338–353, 1965.

[3] E. H. Mamdani e S. Assilian. An experiment in linguistic synthesis with a fuzzy logic controller. *International Journal of Man-Machine Studies*, 7(1):1–13, 1975.

[4] E. Hüllermeier. Fuzzy machine learning and data mining. *WIREs Data Mining and Knowledge Discovery*, 1(4):269–283, 2011.

[5] Ministério da Saúde. Sinan — Notificações de Dengue 2026 (`DENGBR26.csv`). Portal de Dados Abertos do SUS. Disponível em: `https://dadosabertos.saude.gov.br/dataset/arboviroses-dengue`. Acesso em: 27 out. 2026.

[6] F. Pedregosa et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[7] A. Ankan e A. Panda. pgmpy: Probabilistic graphical models using Python. In *Proceedings of the 14th Python in Science Conference (SciPy)*, 2015.

[8] J. Warner et al. scikit-fuzzy: Fuzzy logic toolkit for SciPy. Disponível em: `https://github.com/scikit-fuzzy/scikit-fuzzy`.

A Prompts utilizados

Seguindo a recomendação do enunciado, registramos abaixo os principais prompts usados com assistentes de IA em cada etapa. Todo o código gerado foi lido, executado e conferido pela equipe.

Etapa 1 — Árvore de decisão.

> *Atue como um especialista em Machine Learning. Tenho uma base de dados pré-processada de notificações de dengue do Sinan 2026 balanceada via undersampling. Preciso implementar uma Árvore de Decisão do zero usando o algoritmo ID3 com Entropia e Ganho de Informação para prever a variável-alvo binária HOSPITALIZ (1 = Sim, 2 = Não). Faça a seleção de atributos calculando o ganho de informação dos 17 atributos candidatos (perfil, sintomas e região). Mostre detalhadamente os cálculos de entropia e ganho de informação para os Níveis 1, 2 e 3 da árvore. Compare os resultados do ID3 do zero com o DecisionTreeClassifier do scikit-learn, valide com 5-fold cross-validation no treino e discuta a monotonicidade e as limitações do aprendizado indutivo frente ao tamanho da amostra.*

Etapa 2 — Regressão linear e logística.

> *Atue como um cientista de dados. Na primeira parte, agregue os dados por município (mínimo de 100 casos) e crie modelos de Regressão Linear univariada e multivariada (via Gradiente Descendente vetorizado implementado do zero) para prever a taxa contínua de hospitalização municipal, aplicando regularização L2 (Ridge) com seleção de lambda por validação cruzada 5-fold. Na segunda parte, volte ao problema de classificação do paciente individual e implemente do zero a Regressão Logística (com função sigmoide e gradiente da entropia cruzada) comparando com o scikit-learn. Interprete os coeficientes como razões de chance (odds ratios) para os atributos (leucopenia, vômito, hipertensão, faixa etária e região).*

Etapa 3 — Probabilidade.

> *Atue como um estatístico. Utilizando a base completa e não balanceada de dengue (346.765 registros) com as variáveis HOSPITALIZ, LEUCOPENIA e VOMITO, calcule as distribuições conjuntas de probabilidade. Determine as probabilidades marginais e condicionais de hospitalização $P(H \mid L)$ e $P(H \mid \neg L)$. Demonstre a Regra da Cadeia $P(H, L, V)$ e aplique o Teorema de Bayes para comparar a direção causal $P(L \mid H)$ com a direção diagnóstica $P(H \mid L)$. Por fim, avalie matematicamente se LEUCOPENIA e VOMITO são condicionalmente independentes dada a hospitalização e discuta as limitações da lógica de primeira ordem em relação à incerteza nos dados clínicos.*

Etapa 4 — Naive Bayes e EM.

> *Atue como um especialista em modelos probabilísticos. Implemente o algoritmo Naive Bayes do zero comparando estimadores de Máxima Verossimilhança (MLE) e Máximo a Posteriori (MAP com suavização de Laplace) sobre a base balanceada de treino da Etapa 1. Em seguida, relaxe a premissa de independência condicional introduzindo uma variável oculta Z com K componentes por classe e implemente o algoritmo Expectation-Maximization (EM) para aprender os parâmetros. Compare o Naive Bayes puro com o EM ($K = 2$ e $K = 3$) avaliando log-verossimilhança, acurácia, AUC e log-loss no teste, e analise quais perfis clínicos de pacientes a variável oculta Z conseguiu capturar.*

Etapa 5 — Redes Bayesianas.

> *Atue como um especialista em Redes Bayesianas. Construa um Grafo Acíclico Dirigido (DAG) de 6 nós (HOSP, faixa_etaria, HIPERTENSA, regiao, LEUCOPENIA, VOMITO) representando as relações causais e diagnósticas de infecção por dengue. Estime as CPTs no treino com MAP e aplique a correção de prevalência real (8,56%). Implemente o algoritmo de Inferência por Enumeração do zero e valide seus resultados com a Eliminação de Variáveis da biblioteca pgmpy. Demonstre o conceito de d-separação e a abertura de caminhos ao observar um nó colisor (HOSP), comparando a economia de parâmetros da rede em relação à distribuição conjunta completa.*

Etapa 6 — Lógica fuzzy. A primeira versão desta etapa foi desenvolvida por Nelson com o seguinte prompt:

> *Atue como um especialista em Lógica Fuzzy. Crie um sistema de inferência do tipo Mamdani em Python usando dados de teste para avaliar o risco de hospitalização por dengue em uma escala de 0 a 100. Defina regras baseadas nos sintomas do paciente e mostre os resultados de acurácia, precisão e recall.*

Na revisão, essa versão foi corrigida e refeita em uma conversa com um assistente de IA (próximo item). A versão final, descrita na Seção 8, resultou dessa conversa, e não de um prompt único.

Revisão, correções e relatório. A conferência dos notebooks, a correção da Etapa 6 e das importações das Etapas 4 e 5, e a primeira versão deste relatório foram feitas por Lívia e Antony em uma conversa com um assistente de IA, a partir dos notebooks e do enunciado. Os principais pedidos foram:

> *"Me mande tudo que estava incorreto de acordo com o que o professor solicitou."*
> *"Analise os dados com o que está no relatório?"*
> *"Analise" (sobre a versão compilada do relatório), seguido de correções e os cortes sugeridos."*